

Resumen de la Etapa 3

Preparación de datos y Feature Engineering (P1)

Vertex Insights — Proyecto Final
Fase CRISP-DM: Data Preparation · Tag V1.2.0
Problema P1: predicción de entrega tardía (entrega_tarde)
Fecha de cierre: 2026-06-20 · Sprint 1

Líder de etapa: Data Scientist — Aguilar Lomas, Oscar Amaury

1. Contexto y objetivo

La Etapa 3 es el corazón de la fase **Data Preparation** de CRISP-DM. Su objetivo fue convertir los hallazgos del EDA (Etapa 2) en una **tabla analítica modelable** y un **pipeline reproducible** para el problema vigente **P1 — predicción de entrega tardía** (entrega_tarde), sin reabrir el pivote ya decidido en la Etapa 2. Se entregó la tabla analítica a nivel orden con el target y las features [t0], el pipeline de preprocesamiento serializado, el split temporal sin leakage y un EDA breve que evidencia los cambios del ETL+FE. La disciplina anti-leakage (R-12) fue el eje rector de la etapa.

2. Productos entregados

- **Script reproducible de ETL + FE** (src/features/build_dataset.py): colapsa a nivel orden sobre 'delivered', construye target y features [t0], calcula la tasa del vendedor sin fuga y serializa el pipeline.
- **Tabla analítica de P1** (orders_p1_features.csv): 96,470 órdenes × 21 columnas (identificadores, split, target, features [t0]).
- **Pipeline de preprocesamiento serializado** (artifacts/pipeline_p1.joblib): ColumnTransformer ajustado solo en train + metadatos.
- **EDA breve de cambios** (notebooks/03_EDA_VERTEX.ipynb): 7 figuras antes/después exportadas a reports/figures_eda_etapa3/.
- **Documento técnico de FE** (docs/decisiones_fe.md): catálogo de features, ventana del vendedor, imputación, encodings, split y multicolinealidad.

3. Decisiones clave (bitácora)

ID	Decisión
D-22	Fuente del FE: CSV consolidado en vez de las 9 tablas crudas.
D-23	Granularidad a nivel orden; vendedor/producto = primer ítem; importes/peso/volumen agregados.
D-24	Tasa del vendedor: expanding point-in-time, mín. 5 órdenes, respaldo a tasa global + flag.
D-25	Split temporal 70/15/15 por fecha de compra.
D-26	Imputación con sentido de negocio + pipeline serializado (ColumnTransformer).

4. Resultados y verificaciones clave

Métrica de la etapa	Valor
Órdenes en la tabla analítica (delivered, etiquetables)	96,470
Tasa base entrega_tarde	8.11%
Split temporal (train / val / test)	67,529 / 14,470 / 14,471
Tasa global del vendedor (respaldo, train)	9.03%
Órdenes sin historial suficiente del vendedor	11.57%
Distancia haversine nula (geo faltante, imputada)	476 (0.49%)

Prueba anti-fuga de la tasa del vendedor	OK
Sanity check regional (SP vs AL)	5.9% vs 23.9% ($\approx 4\times$)

El gradiente regional y el colchón de la promesa del EDA de la Etapa 2 se reproducen sobre las features construidas, lo que confirma que el FE preserva la señal de negocio.

5. Galería de gráficas (EDA de cambios)

Las siguientes figuras documentan el antes/después del ETL+FE. Se exportaron en PNG a 150 dpi desde notebooks/03_EDA_VERTEX.ipynb.




Figura 1 — Granularidad y universo: del CSV consolidado a la tabla analítica a nivel orden sobre 'delivered' (96,470 órdenes etiquetables).




Figura 2 — Distribución del target 'entrega_tarde': tasa base de 8.11% (problema desbalanceado).




Figura 3 — Gradiente regional de entrega tardía: SP 5.9% vs AL 23.9% ($\approx 4\times$), señal de negocio preservada tras el FE.




Figura 4 — Distribuciones de las features [t0] construidas (importes, peso/volumen, distancia haversine, colchón de promesa).




Figura 5 — Tasa histórica del vendedor point-in-time (expanding, mín. 5 órdenes) con respaldo a la tasa global del train; prueba anti-fuga OK.




Figura 6 — Nulos antes/después del ETL+FE: imputación con sentido de negocio; distancia haversine nula en 0.49% (unión de huecos geo).




Figura 7 — Split temporal 70/15/15 por fecha de compra (67,529 / 14,470 / 14,471) y vigilancia del régimen 2018 (R-14).

6. Lecciones aprendidas

- El leakage se previene por construcción, no por revisión: la tasa del vendedor point-in-time con prueba anti-fuga automática es más fiable que auditar a posteriori.
- Imputar con la causa del hueco en mente: geo, vendedor nuevo y dimensiones faltantes piden estrategias distintas; un fillna(0) global habría borrado señal.
- Una feature derivada hereda la unión de los huecos de sus fuentes: los nulos de la distancia (0.49%) son la suma de geo cliente + vendedor.
- El split temporal es parte del feature engineering: la tasa global de respaldo y el preprocesador se ajustan solo en train.
- Reusar trabajo validado acelera sin perder rigor: partir del consolidado fue una decisión de tiempo razonable y trazable.

7. Próximos pasos — Etapa 4 (Modelado)

La Etapa 4 arranca con la tabla analítica y el pipeline de preprocesamiento ya listos. Toma como insumo el split temporal y la disciplina anti-leakage de esta etapa. Foco: añadir el estimador al Pipeline, entrenar un baseline y modelos (regresión logística, árboles/boosting), evaluar con ROC-AUC/PR-AUC/F1 sobre el split temporal y vigilar la tasa_vendedor y el régimen 2018. Tag esperado al cierre: V1.3.0.